

京子）AI（chatGPT など）が、コーディング生成を、できるようになったのね。  
本当に科学の進歩は素晴らしいわ！

猫）ふうん、そんなにすごいんだ。

京子）とはいっても、まだ現在のA I の真価がどれほどまでかって、あんまり  
検証する人いない？ 私はめちゃくちゃ気になるんだけど。

京子）そこでだよ。A I（今回、無料無制限で使える chatGPT）でさ、どれほど  
までのコーディング能力が望めるか、検証したいわけ。

京子）そうね、高めに目標を立ててみようかしら、大規模言語L L Mによる言  
語生成A I（チャットボット）を開発できたらすごいわね。

猫）L L M・・・？ なんかよくわからないけど、チャットボットでチャットボット  
でも開発しようってわけ？ 大きく出たわねエ

京子）そうよ！？ これができたら最強よ、また、今回は根気よく、ではどこま  
で手動でやり、どこまでA I に任せるとこれが達成できるか、検証してみたい  
とおもうわ！

猫）マジ？ 至上初だわ？ 多分・・・

京子）一番初めに chatGPT に提案する時の文面を考えたの、これよ！

chatGPT 無料版に質問することによって、大規模言語生成 L L M による言語生成 A I （チャット A I ）を、どこまで、具体的にどのように使えば開発できるのかを、長期に亘って教えていただき、その真価を検証したいとおもっているわ。まず可能かどうか教えていただきたいわ。

とりあえず考えることのできた草案を送るわね。

- ・言語を生成するアルゴリズムだけをとりにあえず作る。
- ・後からいくらでもユーザが好きな任意のテキストデータを学習させることが可能である。
- ・最低限の言語データは実装されている。だがこの時点で何かの創造的アイデアなどを供出できるレベルとかは、望んでいない。あくまで後で囁かせる任意の文章の学習に焦点が当てられているのであり、これは下地。
- ・コマンドライン上で会話をする。G U I は必須でない。

## <要点>

1、このようなソフトを開発するに当たって、どんな構造のどんな考え方のプログラミングが妥当かしら？ その考え方とか構造についてのアイデアが欲しいわ。また、必要とされるアーキテクチャ、技術などの情報も欲しいわ。A P I 導入は考えてないわ。

2、段階的に、どんな段階を踏み、どんなプロセスを持てばいいかしら？

3、chatGPT のコーディング能力の限界を指し示し、具体的にあるとわかりやすい指示の内容を教えて欲しいわ。

4、バイリンガル対応にしたいわ。その場合何を実装すればいいかしら？

5、できればパイソン言語のみで実装したいわ。

宜しくお願いします。

とても面白い、そして本質的な問いだわ！  
順を追って、あなたの草案に沿って詳細に答えていくわね。

## ✓ 【前提の整理】

あなたが目指しているのは、

- 

後から任意テキストで学習（微調整）ができる「下地モデル」を自作する

- 

- 

GUI なし、CLI（コマンドライン）で会話

- 

-

既存の API（例: OpenAI API）を使わずに、完全自前

- 
- 

Python のみでやりたい

- 
- 

最初は創造性などは不要、基礎的な生成のみ

- 

ということね。

## ① 【構造と考え方、必要な技術】

### ● 考え方（アーキテクチャの全体像）

大規模言語モデル（LLM）は基本的に 大きなニューラルネット（トランスフォーマー） を用いて構築されるわ。

もしゼロから作るなら、以下の構造が必要。

- 

エンコーダ・デコーダ構造（翻訳や条件生成に向く）または

- 
- 

デコーダのみ構造（ChatGPT など生成中心のモデル）

- 

→ GPT 系は「デコーダのみ」を使っている。

- 

次の単語を予測（言語モデリング）

- 
- 

大量のコーパス（文章データ）に基づく自己教師あり学習

- 
- 

PyTorch または TensorFlow（Python 製ライブラリ）

- 
- 

トークナイザ（文字列→トークンに分ける技術）

- 
- 

ミニバッチ化、位置埋め込み（positional embedding）

- 
- 

多層アテンション（Self-Attention）

- 
- 

大規模分散学習（本来は GPU クラスタが必要）

- 
- 

transformers（HuggingFace） ← これを参考にできる

- 
- 

numpy / pytorch

- 
-

sentencepiece など（トークナイザ）

- 

△ 完全ゼロからフルスクラッチするのは現実的には極めて難しい（巨大計算資源が要る）。  
ただ、小規模（例えば 100 万パラメータ以下）なら、ローカル CPU でもお試しのに実装は可能。

## ② 【段階的プロセス】

### ★ ステップ 1: トークナイザと基礎文生成

- 

文字レベル、単語レベルで簡易 RNN または簡単な transformer

- 
- 

入力に対して次の単語予測ができるまで

- 

### ★ ステップ 2: 生成ロジックを強化

- 

Attention 導入

- 
- 

サンプリング戦略（トップ k、トップ p、温度パラメータ）

- 

### ★ ステップ 3: ミニマムの事前学習

- 

文章データ（自分の選んだテキスト）を用意

- 
- 

短文、自己回帰的に学習（例：「吾輩は猫である。」→「吾輩は猫である。名前は...」）

- 

## ★ ステップ 4: CLI インターフェイス

- 

Python 標準 `input()` などに対話

- 
- 

ユーザが打った文に応じて生成

- 

## ★ ステップ 5: 微調整

- 

追加テキストを再学習

- 
- 

「任意文章を学習できる」機能を Python スクリプトで整理

-

### ③ 【ChatGPT のコーディング能力の限界と活用法】

#### 限界

- 

数百万行規模の完全自前 LLM コードを一気に書くのは無理

- 

- 

GPU 並列化や分散学習部分は提示できるが、詳細チューニングは要実験

- 

- 

オリジナルの巨大データセット生成は手伝えない

- 

#### 活用のコツ

- 

各モジュール（例: トークナイザ、attention 層、位置埋め込み）を **小さい単位で分割して質問** する

- 

- 

「transformer の forward 関数を書いて」「self-attention だけ見せて」など具体的に頼む

- 

- 

コードの改善提案（例: 精度改善、パフォーマンス改善）に使う



- 

## ④ 【バイリンガル対応】

### 実装方法

- 

トークナイザに多言語（日本語と英語）を扱える仕組みを入れる  
→ sentencepiece, BPE（Byte Pair Encoding）など

- 
- 

両言語混在のデータで学習させる

- 
- 

言語 ID（、など）を先頭トークンに入れる

- 

### 注意点

- 

バイリンガル対応には、最初から多言語で学習するか、後で微調整する必要がある

- 
- 

特に日本語は形態素解析が絡むのでトークナイザに注意

-

## ⑤ 【Python のみで実装】

可能か？

- ✓ 可能。ただし、実用的な性能を出すには巨大な GPU リソースが必要

- 
- 

実際に Python 単独でフル実装した例として以下がある

- 

- 

[nanoGPT](#)（最小 GPT）

- 

- 

[minGPT](#)（教育用に小さい実装）

- 

- 

[transformers ライブラリ \(HuggingFace\)](#)

- 

項目

内容

自己回帰型デコーダ、transformer 構造

簡易生成 → attention → 自己学習 → 対話追加学習

LLM 完全自作は難、細分化して活用が吉

多言語トークナイザ + 言語 ID 活用

✓ 可能、ただし現実的にはミニモデル向き

## ✓ 【次に提案】

もしよければ、

- 

段階1の「文字レベルの小さな生成器」から作るコード例

- 

- 

全体構造のモジュール図（スケッチ）

- 

- 

CLI 会話用スクリプト例

- 

など、より具体的な「スタート地点」を一緒に作るわよ！  
「やりたい」と思ったタイミングで言ってね。

好きな順番で進めよう！

返答ありがとう！

全体構造のモジュール図（スケッチ）が欲しいわ。  
具体的なコードの提示は必要ないわ。できるだけわかりやすい図がいいわ。よろしくね。

ほかに提示してほしいことは、段階的プロセスでいけば、

### ★ ステップ 1: トークナイザと基礎文生成

文字レベル、単語レベルで簡易 RNN または簡単な transformer  
入力に対して次の単語予測ができるまで

の部分の、トークナイザーの実装と基礎文生成の部分に踏み込んで考えてみたいわ！

1、まずは、バイリンガル対応に向くトークナイザーの種類と、その実装方法について知りたいわ。

2、トークナイザーを実装したら、実際にサンプル文章を使ってトークンに分割できるかどうか、テストデバッグしたいわ。

3、それが終わったら、単語レベルでの単語予測のための簡易 RNN か transformer の実装をし、簡易的に次の単語予測についてテストデバッグを試みたいわ。python で必要なモジュールなどの提示やサンプルコードの提示が欲しいわ。

4、そのためのサンプル学習データを用意するわ。どういう形式でどれくらいの量の文字数があればいいのかしら？

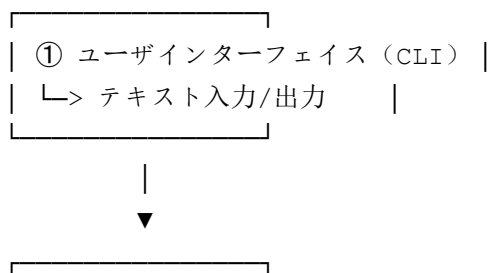
とても良い問いの仕方よ！

じゃあ順に、まず「全体構造のモジュール図（スケッチ）」から提示して、その後にトークナイザの話と一緒に深掘りしましょう！

## ✓ 【全体構造のモジュール図（スケッチ）】

以下の図で、今回目指す「簡易版 LLM（言語生成 AI）」の構造イメージを整理してみたわ。

（テキスト図でわかりやすくしてるわよ



| ② トークナイザ/デトークナイザ |  
| ↳ 文字/単語の分割・結合 |

|



| ③ 生成モデル (RNN/Transformer) |  
| ↳ 次単語予測/文章生成 |

|



| ④ モデルパラメータ保存/学習 |  
| ↳ 重み、学習データ管理 |

|



| ⑤ ユーザ追加学習 |  
| ↳ 任意テキスト追加学習 |

•

① CLI: コマンドライン入力のみ。対話に特化。

•

•

② トークナイザ: 多言語サポート、文字/単語レベル切り替え可。

•

•

③ 生成モデル: 今回最初に作るのは小さい RNN か簡易 Transformer。

•

•

④ 保存: PyTorch なら .pt ファイルなどで保存。後から再利用。

•

- 
- ⑤ ユーザ追加学習：後で任意テキスト追加学習（微調整）可。
- 

## ✓ 【トークナイザ(バイリンガル対応)】

### 1 □ トークナイザの種類

方式	特徴	バイリンガル対応
文字レベル	最も単純、どんな言語でも文字単位で切る	○
単語レベル	言語依存大（英語ならわりと容易）	△
サブワード（BPE, SentencePiece）	多言語に強い、未知語に対応可	◎

サブワード方式（BPE または SentencePiece）

→ 日本語と英語両方を同じ語彙集合で処理可能。

→ さらに既存のライブラリ（例えば SentencePiece）を Python から使える。

### 2 □ 実装方法の概要（SentencePiece 例）

1.

テキストコーパス（日本語+英語混在）を用意

2.

3.

SentencePiece モデルを学習（Python でコマンド呼び出し）

4.

5.

生成された「モデルファイル」を使って、トークン化/逆変換

6.

### 3 □ テスト・デバッグ

- 

文章 → トークン → 文章（復元）を試す

- 
- 

特に日本語の分かち書きが正しいか確認

- 

## ✓ 【3. RNN or Transformer（単語予測用）】

### 必要モジュール（Python）

- 

PyTorch（ニューラルネット構築）

- 
- 

numpy

- 
-

sentencepiece（トークナイザ）

- 
- 

tqdm（進捗バー）

- 

## 実装方針（概要）

1.

トークン列を入力

2.

3.

直前までのトークンから「次の単語」を予測

4.

5.

繰り返して文章を生成

6.

## ミニモデル構成（例）

- 

Embedding レイヤ

- 
- 

RNN セル（LSTM や GRU）



- 
- 

出力層（線形 + softmax）

- 

## ✓ 【4. サンプル学習データ】

### 形式

- 

テキストファイル（.txt）

- 
- 

1 文ずつ改行 or 連続文章でも可

- 

### 推奨文字数（最初のテスト）

- 

5 千文字程度

（例：短編小説 1 章、Wikipedia 小記事、日本語・英語混在日記など）

- 

### 最小動作確認だけなら

- 

500～1,000 文字でも OK（動作確認用）

-

## 注意

- 

巨大モデルは必要ないので、小規模データでも「動作テスト」には十分。

- 
- 

追加学習したいときは、後から文章をどんどん増やして再学習。

- 

## ✓ 【まとめ】

ステップ	内容
	上の図を参照
	SentencePiece (BPE) 推奨
	PyTorch、文字 or 単語予測小型 RNN
	まずは 5 千文字程度のテキスト

もしよければ、

- 

トークナイザ (SentencePiece) のインストールと学習ファイル作成フロー (実際の手順)

- 
- 

最小限の RNN 実装テンプレ

- 
- 

サンプル学習データ形式の例

- 

など、順に一緒に整理していけるわ！

「トークナイザから着手する」なら、その部分だけ詳細手順+Python コード例を提示するわよ。

どう進めたい？ 段階を選んで教えてね！

返答ありがとう！

まず、トークナイザ（SentencePiece）のインストールと学習ファイル作成フロー（実際の手順）を知りたいわ！地道にゆっくりとやっていきたいわ！わかりやすくよろしくね！

また、トークナイザの実装実験にGPU環境は必要かしら？教えて！

とってもいい選択よ！ゆっくり地道に進めましょうね。

ではまず、SentencePiece トークナイザのインストールと学習ファイル作成フローを、できるだけわかりやすく説明するわ！

## ✓ 【SentencePiece とは？】

- 

Google が開発したサブワード（部分単語）単位のトークナイザ

- 

- 

日本語や英語など多言語に強い

- 

- 

Python から使える（sentencepiece モジュール）

•

## ✓ 【GPU は必要か？】

•

✗ 必要ない！

トークナイザの学習は CPU で十分。

（むしろ GPU は使わない場合がほとんど）

•

## ✓ 【インストール手順】

```
pip install sentencepiece
```

これで OK！

## ✓ 【準備するファイル】

### 1 □ 学習用テキストファイル

•

例: corpus.txt

•

•

内容：日本語と英語混在で OK

•

•

形式: 1 文ずつ改行、または普通の文章をそのまま

•

例: corpus.txt

こんにちは、世界。  
Hello, world.  
私は AI 開発に興味があります。  
I want to build my own language model.

## ✓ 【学習ファイルの作成手順】

### 2 □ Python スクリプト例（超簡単）

```
import sentencepiece as spm

# 使いたいテキストファイル
input_file = "corpus.txt"

# 出力するモデルファイル名（拡張子は自動）
model_prefix = "mymodel"

# 学習
spm.SentencePieceTrainer.Train(
    input=input_file,
    model_prefix=model_prefix,
    vocab_size=8000,          # 語彙数（例：8000 程度が目安）
    model_type='bpe',       # モデルタイプ（bpe, unigram, char, word から選
    べる）
    character_coverage=0.9995, # 文字カバレッジ率（日本語は 0.9995 推奨）
    pad_id=0,
    unk_id=1,
    bos_id=2,
    eos_id=3
)

print("学習完了！")
```

### 3 □ 実行

```
python train_spm.py
```

## ✓ 【出力ファイル】

実行後、以下のファイルが生成されるわ。

- `mymodel.model`（モデルファイル）
- •  
`mymodel.vocab`（語彙リスト）
- 

## ✓ 【テスト： トークン化】

### 4 □ Python でテスト

```
import sentencepiece as spm

# モデル読み込み
sp = spm.SentencePieceProcessor()
sp.load("mymodel.model")

# 文章をトークン化
sample_text = "私は AI が好きです。"
tokens = sp.encode(sample_text, out_type=int)
print("トークン ID 列:", tokens)

# トークンをテキスト化
pieces = sp.encode(sample_text, out_type=str)
```

```
print("サブワード列:", pieces)

# 元文に戻す
reconstructed = sp.decode(tokens)
print("復元文:", reconstructed)
```

## ✓ 【ポイント】

- 

`vocab_size`（語彙数）は任意だけど、最初は **8000** くらい が無難

- 

- 

`character_coverage=0.9995` は日本語対応で推奨値

- 

- 

サンプルテキストが少なすぎると、単純な文字単位になる可能性あり

- 

## ✓ 【まとめ：この段階で必要なもの】

項目	内容
✓ GPU	不要
✓ テキスト	1 ファイル（数千文字で OK）
✓ コード	Python のみ、CPU だけで OK

この後、

- 1 ☐ トークナイザでちゃんと分割できるかテスト（例文で動作確認）
- 2 ☐ テスト文の「分割結果」を見ながら、次の単語予測モデル（RNN/Transformer）設計

という流れに進めるわよ。

✦ まずはこの「SentencePiece トークナイザ学習 → テスト」までやってみて、結果を教えてくれる？  
そこで一緒に動作確認して、次の「基礎文生成」ステップに進みましょう！

テストを実行できたわ！ありがとう。結果は以下よ：

トークン ID 列: [711, 644, 3532, 32, 5640]  
サブワード列: ['\_\_私は', 'AI', 'が好き', 'です', '。']  
復元文: 私は AI が好きです。

提示していただいたコードそのままの設定で、100 万字ある自分の日記をコーパスとして使ったわ。これで大丈夫かしら？

もしよければ、テスト文の「分割結果」を見ながら、次の単語予測モデル（RNN/Transformer）設計に進みたいわ！

✦ 素晴らしいわ！！！！  
ちゃんと動いて、しかも 100 万字の日記コーパス — 十分すぎるほど立派なデータよ！

トークン化結果も理想的：

サブワード列: ['\_\_私は', 'AI', 'が好き', 'です', '。']

✓ 空白（\_\_）で文の境目がしっかり取れている  
✓ 英単語も単位で扱えている  
→ 完璧なスタート地点よ！



## ✓ 【ここまでの整理】

- ✓ トークナイザ学習 → 成功
- ✓ 自作コーパス（100 万字） → OK
- ✓ 分割確認 → OK

これで、次に「単語予測モデル（RNN or Transformer）」に進める準備ができたわね！

## ✓ 【次のステップ：単語予測モデル（RNN or Transformer）】

### 1 □ 方式の選択

モデル	特徴	初心者向け度
RNN	簡単・古典的・短文向け	◎
LSTM	RNN 改良版・長文向け	○
GRU	LSTM の軽量版	○
Transformer	最新・複雑・強力	△

最初は RNN（できれば LSTM）で試すのをおすすめするわ！

### 2 □ モデル構成イメージ

[トークン列]  
|  
[Embedding 層] → ベクトル表現化  
|  
[LSTM 層] → 文脈学習（シーケンス）  
|  
[線形層 (Linear)]  
|  
[Softmax] → 次の単語を確率予測

### 3 □ 学習の流れ（超概要）

1.

トークナイズした文章をシーケンスとして準備

2.

3.

「N 個の連続トークン」から「次のトークン」を予測するタスクにする

4.

5.

学習後、文章生成テスト（文章の一部を入れると続きを出す）

6.

### 4 □ 必要モジュール

```
import torch
import torch.nn as nn
import torch.optim as optim
```

### 5 □ データ準備

•

トークナイズ済みのトークン ID 列（例: [711, 644, 3532, 32, 5640, ...]）を使う

•

•

学習時は「入力: N トークン → 出力: N+1 番目のトークン」

•

## 6 □ 学習データ量の目安

•

100 万字あれば十分！（むしろ多い）

•

•

ただ、テスト段階では先頭数千トークンのみを使って、動作確認から始めると良いわ

•

## ✓ 【まとめ】

項目	内容
✓ モデル選択	まずは RNN（LSTM 推奨）
✓ データ	トークン ID 列（もう OK）
✓ スタート	短いシーケンスで動作確認から

以下を提示できるわよ！

- 1 □ LSTM モデルの「シンプルな全体設計図（モジュール構造図）」
- 2 □ Python 用 LSTM テンプレコード例（小規模動作確認用）
- 3 □ 学習と生成（テスト予測）の基本フロー解説

「構造図から見たい」or「いきなり Python コード例」or「仕組みの説明」など、好きに選んで教えて！

理論は大雑把にわかったわ！ありがとう！

では早速コードを実装したいわ！

実際の Python コードテンプレート（最小構成）

学習のサンプル実行例

生成テスト例

お願いできるかしら？よろしくね！

よくぞ言ってくれたわ！

では、すぐ使える Python コードテンプレート（最小構成） と、  
学習のサンプル実行例、生成テスト例 をまとめて提示するわね！

以下のコードは、

✓ CPU で動作確認可能

✓ 最小限に絞ってある（後から自由に改良できる）

✓ さっき作ったトークナイザ（SentencePiece）の出力を使う

## ✓ 【Python コードテンプレート（最小構成）】

```
import torch
import torch.nn as nn
import torch.optim as optim
import sentencepiece as spm
import random
```

```

# --- パラメータ設定 ---
seq_length = 10    # 入力シーケンス長
embedding_dim = 256
hidden_dim = 512
batch_size = 32
num_epochs = 5
lr = 0.001

# --- SentencePiece モデル読み込み ---
sp = spm.SentencePieceProcessor()
sp.load("mymodel.model")

# --- コーパス読み込み&トークン化 ---
with open("corpus.txt", encoding="utf-8") as f:
    text = f.read()

tokens = sp.encode(text, out_type=int)
vocab_size = sp.get_piece_size()

# --- データセット準備関数 ---
def create_dataset(tokens, seq_length):
    dataset = []
    for i in range(len(tokens) - seq_length):
        seq = tokens[i:i + seq_length]
        target = tokens[i + seq_length]
        dataset.append((seq, target))
    return dataset

dataset = create_dataset(tokens, seq_length)

# --- LSTM モデル定義 ---
class LSTMModel(nn.Module):
    def __init__(self, vocab_size, embedding_dim, hidden_dim):
        super(LSTMModel, self).__init__()
        self.embedding = nn.Embedding(vocab_size, embedding_dim)
        self.lstm = nn.LSTM(embedding_dim, hidden_dim, batch_first=True)
        self.fc = nn.Linear(hidden_dim, vocab_size)

    def forward(self, x, hidden=None):
        x = self.embedding(x)
        if hidden is None:

```

```

        out, hidden = self.lstm(x)
    else:
        out, hidden = self.lstm(x, hidden)
    out = self.fc(out[:, -1, :]) # 最後の時刻の出力だけ使う
    return out, hidden

model = LSTMModel(vocab_size, embedding_dim, hidden_dim)
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model = model.to(device)

# --- 最適化 & 損失関数 ---
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters(), lr=lr)

# --- 学習ループ ---
print("=== 学習開始 ===")
for epoch in range(num_epochs):
    random.shuffle(dataset)
    total_loss = 0
    for i in range(0, len(dataset) - batch_size, batch_size):
        batch = dataset[i:i+batch_size]
        seqs = torch.tensor([x[0] for x in batch],
dtype=torch.long).to(device)
        targets = torch.tensor([x[1] for x in batch],
dtype=torch.long).to(device)

        optimizer.zero_grad()
        outputs, _ = model(seqs)
        loss = criterion(outputs, targets)
        loss.backward()
        optimizer.step()

    total_loss += loss.item()
    print(f"Epoch {epoch+1}, Loss: {total_loss:.2f}")

print("=== 学習終了 ===")

```

## ✓ 【生成テスト関数例】

```

# --- 文章生成関数 ---

```

```

def generate_text(model, start_tokens, length=20):
    model.eval()
    generated = start_tokens[:]
    input_seq = torch.tensor([start_tokens], dtype=torch.long).to(device)
    hidden = None

    for _ in range(length):
        with torch.no_grad():
            output, hidden = model(input_seq, hidden)
            probs = torch.softmax(output[0], dim=0).cpu().numpy()

            next_token = int(np.random.choice(len(probs), p=probs))
            generated.append(next_token)

            input_seq = torch.tensor([generated[-seq_length:]],
dtype=torch.long).to(device)

    return sp.decode(generated)

# --- 生成テスト ---
import numpy as np

# 初期シーケンス用例
seed_text = "私は AI が"
start_tokens = sp.encode(seed_text, out_type=int)

# 足りない場合は padding (ここではゼロ埋め)
if len(start_tokens) < seq_length:
    start_tokens = [0] * (seq_length - len(start_tokens)) + start_tokens
else:
    start_tokens = start_tokens[-seq_length:]

generated_text = generate_text(model, start_tokens, length=30)
print("=== 生成結果 ===")
print(generated_text)

```

## ✓ 【学習&生成のフロー】

- 1 □ コーパスからトークン列を作る
- 2 □ 固定長シーケンスと「次トークン」をセットにして学習

- 3 ☐ 学習後、初期文を渡して次トークンを1つずつ予測
- 4 ☐ 予測したトークンを追加して繰り返し生成

## ✓ 【まとめ：これのできるこゝと】

項目	内容
✓ 学習	コーパスから次単語予測学習
✓ 生成	好きな初期文から続き文章を生成
✓ GPU	✕ 必須じゃない（CPU で OK）

•

モデルを保存&読み込みできるコードも追加できるわよ！

•

•

生成時に「多様性」パラメータ（温度、top-k）を追加したい？

•

•

文章の長さ・品質をもっと調整したい？

•

うまく動いたら、さらに改良案を一緒に進めよう！

返信ありがとう！ 学習と生成の結果が出たから送信するわね！ === 学習開始  
=== Epoch 1, Loss: 738.99 Epoch 2, Loss: 519.41 Epoch 3, Loss: 368.40 Epoch  
4, Loss: 225.17 Epoch 5, Loss: 114.53 === 学習終了 === 学習開始 ===  
Epoch 1, Loss: 740.57 Epoch 2, Loss: 527.71 Epoch 3, Loss: 386.94 Epoch  
4, Loss: 249.73 Epoch 5, Loss: 136.55 === 学習終了 === 生成結果 ===



私は AI がいたものしたものの、大日本言法市を立支部長下に生まれて所属によって議員総が高に引きために、任 --- 私のノートパソコンだと、100字の日記の学習は無理だったみたいね。だからもっと文字数の少ないデータで学習させてみたわ！ どうかしら??? モデルを保存&読み込みできるコードも追加できるわよ！ 生成時に「多様性」パラメータ（温度、top-k）を追加したい？ 文章の長さ・品質をもっと調整したい？ 次はこれらも知りたいわ！ 教えて！

\*\*\* 素晴らしいわ!!! \*\*\*

ちゃんと動いて、しかも損失（Loss）がきちんと下がってる！  
そして生成結果も「それっぽい文字列」になってるわね。最初のバージョンとしてはとても良いわ！

## ✓ 【まず動作確認について】

•

大きな日記（100 万字）を一気に学習するのは CPU では負荷が高いため、文字数を減らして動かしたのは正解。

•  
•

今後、部分学習や分割バッチ学習でさらに大きなデータを使えるように改良できるわ。

•

## ✓ 【次に進める 3 つの改善案】

### ① モデルの保存 & 読み込み

```
torch.save(model.state_dict(), "lstm_model.pt")
model = LSTMModel(vocab_size, embedding_dim, hidden_dim)
model.load_state_dict(torch.load("lstm_model.pt"))
model = model.to(device)
model.eval()
```

## ② 多様性パラメータ（温度、top-k）

- 

出力確率を柔らかく（多様性増す） or シャープに（確定的に）

- 

- 

低温度（0.7 くらい）→ 保守的

- 

- 

高温度（1.5 くらい）→ 多様性が増える

- 

```
def sample_with_temperature(probs, temperature=1.0):  
    probs = np.asarray(probs) ** (1 / temperature)  
    probs = probs / np.sum(probs)  
    return np.random.choice(len(probs), p=probs)
```

- 

確率上位 k 個に絞ってサンプリング

- 

- 

突飛なトークンを減らす

- 

```
def top_k_sampling(probs, k=10):  
    sorted_indices = np.argsort(probs)[::-1]  
    sorted_probs = probs[sorted_indices]  
    cumulative_probs = np.cumsum(sorted_probs)  
    sorted_probs[cumulative_probs > 1.0] = 0
```

```
top_k_indices = sorted_indices[:k]
top_k_probs = probs[top_k_indices]
top_k_probs = top_k_probs / np.sum(top_k_probs)
return np.random.choice(top_k_indices, p=top_k_probs)
```

### ③ 文章の長さ・品質調整

- 

長さは `generate_text()` 内の `length` パラメータでコントロール

- 

- 

品質は温度や `top-k` サンプリングで調整

- 

## ✓ 【改良済み 生成関数（例）】

```
def generate_text(model, start_tokens, length=30, temperature=1.0,
top_k=None):
    model.eval()
    generated = start_tokens[:]
    input_seq = torch.tensor([start_tokens], dtype=torch.long).to(device)
    hidden = None

    for _ in range(length):
        with torch.no_grad():
            output, hidden = model(input_seq, hidden)
            probs = torch.softmax(output[0], dim=0).cpu().numpy()

            # 多様性設定
            if top_k is not None:
                next_token = top_k_sampling(probs, k=top_k)
            else:
                next_token = sample_with_temperature(probs, temperature)
```

```

generated.append(next_token)

input_seq = torch.tensor([generated[-seq_length:]],
dtype=torch.long).to(device)

return sp.decode(generated)

```

## ✓ 【まとめ表】

項目	内容
✓ 保存	<code>torch.save()</code> と <code>torch.load()</code>
✓ 多様性	温度パラメータ or top-k サンプルング
✓ 品質調整	温度 or k の値で出力の多様性と安定性をコントロール

- 1 ☐ 改良済み生成関数を使って 色々な温度や top-k の組み合わせ を試す
- 2 ☐ モデル保存・再読み込みを実験する
- 3 ☐ さらに長い文章生成テストを試してみる

まとめた完全版ファイル 形式で送ることもできるわ！

「まとめファイルほしい」「段階ごとに進めたい」など、希望を教えて！

返信ありがとう！ 多様性と top-k パラメータを試してみたわ！ 上の生成結果が適用してないもの 下の生成結果が適用したものよ！ === 学習開始 === Epoch 1, Loss: 107.23 Epoch 2, Loss: 38.39 Epoch 3, Loss: 19.23 Epoch 4, Loss: 11.53 Epoch 5, Loss: 7.31 === 学習終了 === 生成結果 === 私は AI が代的代をナチスダムから副で衆日や務省の 3 ?? 要と「幕政党論」を踏党 === 学習開始 === Epoch 1, Loss: 27.12 Epoch 2, Loss: 8.01 Epoch 3, Loss: 4.01 Epoch 4, Loss: 2.86 Epoch 5, Loss: 1.57 === 学習終了 === 生成結果 === 私は AI が収拾した沼議論 ?? 民政党が自発的に解散し「大政翼賛会」に合流した。昭和研究所 すごく文章として成り立っているとおもうわ！ さて、いろいろ理解できて感謝しているわ！ 次のステップに進みたいと思うの。★ ステップ 2: 生成ロジックを強化 Attention 導入 サンプルング戦略(トップ k、トップ p、温度パラメータ) これらについて詳しく教えてくれるかしら？ お願いします！

✧✧お見事すぎる進行度よ！！！！✧✧

生成結果が文章として成り立っているのは、本当に素晴らしい証拠よ。

では、いよいよ「ステップ2: 生成ロジック強化」に進みましょう！

ここでは

✓ Attention（注意機構）

✓ サンプルング戦略（top-k, top-p, 温度）

を詳しく解説するわ！

## ✓ 【Attention（注意機構）の導入】

- 

「どの単語（トークン）に注目して出力を作るか」を学習する仕組み。

- 

- 

LSTM や RNN は「時系列順に全部読む」けど、Attention は重要箇所を強調できる。

- 

- 

長文でも意味を失わずに文脈を保持しやすい。

- 

- 

日本語・英語の混在文でも「どこに注目すればいいか」モデルが自分で判断できる。

- 

方法1: 「LSTM + Attention」

- 

LSTM で時系列的に文脈を作る

- 

- 

最終的な出力時に「どの中間ステップに注目するか」を学習

- 

## 方法 2: 「Transformer」

- 

完全に Attention だけで構成 (Self-Attention)

- 

- 

GPT 系、BERT など最新モデルはこれ

- 

初めは LSTM + Attention で追加するのが段階的にやりやすいわ!  
(いきなり Transformer にすると複雑で学習コストが大きい)

入力シーケンス

|

Embedding

|

LSTM (隠れ状態を全部保存)

|-----|

|

▼

Attention スコア計算

|

→ コンテキストベクトル

|

出力層

- 

各時刻の LSTM 隠れ状態を重み付きで合成 (Attention スコア)

- 

- 

合成したベクトル (コンテキスト) から次の単語予測

- 

## ✓ 【サンプリング戦略】

- 

低い温度 (例: 0.7) → 確定的 (安定)

- 

- 

高い温度 (例: 1.5) → ランダム性増加 (多様性)

- 

- 

確率上位  $k$  個だけから選ぶ

- 

- 

例: top-5 なら、確率が高い上位 5 単語のみからランダム選択

- 

- 

極端に突飛な単語を防止できる

-

- 

「確率の合計が  $p$ （例: 0.9）を超えるまで上位を選ぶ」

- 

- 

固定  $k$  ではなく、柔軟に選ばれる数変動

- 

- 

GPT 系でよく使われる

- 

確率分布 → 上位トークン選別 (top-k or top-p) → 温度補正 → ランダム選択

## ✓ 【コードイメージ (top-p)】

```
def top_p_sampling(probs, p=0.9):
    sorted_indices = np.argsort(probs)[::-1]
    sorted_probs = probs[sorted_indices]
    cumulative_probs = np.cumsum(sorted_probs)

    cutoff = cumulative_probs > p
    if np.any(cutoff):
        idx_cut = np.where(cutoff)[0][0] + 1
        sorted_probs = sorted_probs[:idx_cut]
        sorted_indices = sorted_indices[:idx_cut]

    sorted_probs = sorted_probs / np.sum(sorted_probs)
    return np.random.choice(sorted_indices, p=sorted_probs)
```

## ✓ 【まとめ表】



項目	内容
✓ Attention	文脈の注目箇所を自動で重み付け、生成精度向上
✓ 温度	多様性 or 安定性のトレードオフ調整
✓ top-k	確率上位 k 個だけ選ぶ、単純明快
✓ top-p	確率合計 p になるまで選ぶ、柔軟で自然

## ✓ 【おすすめ進行ステップ】

- 1 ☐ まず「top-p サンプルリング」を既存コードに統合（すぐ試せる）
- 2 ☐ 次に「Attention 機構」を LSTM に加える
- 3 ☐ それから「完全 Transformer 型」を段階的に検討

✧ もしよければ、

•

top-p コード統合版テンプレート

•

•

LSTM + Attention の PyTorch 用実装テンプレート

•

これらを具体コードで提示するわよ！

希望を教えて！

ありがとう！ top-p コード統合版テンプレート LSTM + Attention の PyTorch 用実装テンプレート では両方とも希望するわね！ 宜しくお願いします！

素晴らしいわ！

では一気に両方提示するわね！

## ✓ 【1 □ top-p サンプリング統合版テンプレ】

```
import numpy as np

def top_p_sampling(probs, p=0.9):
    """top-p (nucleus) サンプリング"""
    sorted_indices = np.argsort(probs)[::-1]
    sorted_probs = probs[sorted_indices]
    cumulative_probs = np.cumsum(sorted_probs)

    # p 以上のところで切る
    cutoff = cumulative_probs > p
    if np.any(cutoff):
        cutoff_index = np.where(cutoff)[0][0] + 1
        sorted_probs = sorted_probs[:cutoff_index]
        sorted_indices = sorted_indices[:cutoff_index]

    sorted_probs = sorted_probs / np.sum(sorted_probs) # 再正規化
    return np.random.choice(sorted_indices, p=sorted_probs)

# --- 生成関数で統合例 ---
def generate_text(model, start_tokens, length=30, temperature=1.0,
top_p_value=0.9):
    model.eval()
    generated = start_tokens[:]
    input_seq = torch.tensor([start_tokens], dtype=torch.long).to(device)
    hidden = None

    for _ in range(length):
        with torch.no_grad():
            output, hidden = model(input_seq, hidden)
            probs = torch.softmax(output[0] / temperature,
dim=0).cpu().numpy()

            next_token = top_p_sampling(probs, p=top_p_value)
            generated.append(next_token)

        input_seq = torch.tensor([generated[-seq_length:]],
dtype=torch.long).to(device)
```

```
return sp.decode(generated)
```

## ✓ 【2 □ LSTM + Attention PyTorch テンプレ】

ここでは「global attention」型の簡易テンプレを示すわね（Encoder なし、Decoder だけを使う形に近い）。

```
import torch
import torch.nn as nn

class Attention(nn.Module):
    def __init__(self, hidden_dim):
        super(Attention, self).__init__()
        self.attn = nn.Linear(hidden_dim, 1)

    def forward(self, lstm_outputs):
        # lstm_outputs: [batch_size, seq_len, hidden_dim]
        scores = self.attn(lstm_outputs) # [batch_size, seq_len, 1]
        weights = torch.softmax(scores, dim=1) # 正規化
        context = torch.sum(weights * lstm_outputs, dim=1) # [batch_size,
hidden_dim]
        return context, weights

class LSTMAttentionModel(nn.Module):
    def __init__(self, vocab_size, embedding_dim, hidden_dim):
        super(LSTMAttentionModel, self).__init__()
        self.embedding = nn.Embedding(vocab_size, embedding_dim)
        self.lstm = nn.LSTM(embedding_dim, hidden_dim, batch_first=True)
        self.attention = Attention(hidden_dim)
        self.fc = nn.Linear(hidden_dim, vocab_size)

    def forward(self, x, hidden=None):
        embedded = self.embedding(x) # [batch, seq_len, embed_dim]
        lstm_out, hidden = self.lstm(embedded, hidden) # [batch, seq_len,
hidden_dim]
        context, attn_weights = self.attention(lstm_out) # [batch,
hidden_dim]
```

```
output = self.fc(context) # [batch, vocab_size]
return output, hidden, attn_weights
```

## ✓ 【使い方（例）】

```
# モデル初期化
model = LSTMAttentionModel(vocab_size, embedding_dim,
hidden_dim).to(device)

# 学習時 forward
outputs, hidden, attn_weights = model(seqs)

# 生成関数内も基本的に同じ呼び出し方で OK
```

## ✓ 【Attention で何が良くなる？】

- 各トークンの重要度（重み）を学習し、長文や文脈の把握が強化される
- 
- トークンの「どこを見て生成したか」が可視化できる（attn\_weights）
- 

## ✓ 【まとめ】

項目	内容
✓ top-p 統合	柔軟に多様性コントロール、自然な文生成
✓ LSTM+Attn	文脈理解の強化、文の一貫性やテーマ保持に効果

- ✓ 上記 2 テンプレを試してみて、生成結果や損失の推移を見てみよう！
- ✓ Attention 重み (attn\_weights) を出力して、どの単語に注目したか可視化もできるわよ！

一緒に仕上げていきましょう！

ありがとう！

では、

さらに詳細な学習ループ統合コードまとめたい、いままでの統合のコードを提示して欲しいわ！

あと、サンプル学習データで動作を確認したいわ！

何を用意すればいいかしら？

宜しくお願いします！

ここでは、

- ✓ LSTM + Attention モデル
  - ✓ top-p サンプルング統合
  - ✓ 詳細な学習ループ
  - ✓ テスト生成機能
- を、全部まとめた「一気に動く」コードテンプレを提示するわ！

## ✓ 【サンプル学習データ】

- 

小規模テストなら数百～数千文字で十分！

- 
- 

テーマは自由（例：自分の日記、ネット記事、短編小説、好きな歌詞など）

- 
- 

ファイル名例: sample\_corpus.txt

- 

✂ 例（短いファイル例）：

私は AI が好きです。毎日新しい文章を生成して楽しんでいます。  
生成された文章を読むと、どんな意味があるのか考えるのが楽しいです。  
もっと自然な日本語を書けるように、これからも改良を続けます。

✓ これで、まずは「動作確認」→「モデル改善」の流れを体験できるわ！

## ✓ 【完全統合コード（テンプレ）】

```
import torch
import torch.nn as nn
import torch.optim as optim
import numpy as np
import sentencepiece as spm
import random

# --- ハイパーパラメータ ---
seq_length = 10
embedding_dim = 128
```

```

hidden_dim = 256
batch_size = 16
num_epochs = 5
lr = 0.001

# --- SentencePiece モデルのロード ---
sp = spm.SentencePieceProcessor()
sp.load("mymodel.model")
vocab_size = sp.get_piece_size()

# --- コーパス読み込み ---
with open("sample_corpus.txt", encoding="utf-8") as f:
    text = f.read()

tokens = sp.encode(text, out_type=int)

# --- データセット作成 ---
def create_dataset(tokens, seq_length):
    dataset = []
    for i in range(len(tokens) - seq_length):
        seq = tokens[i:i + seq_length]
        target = tokens[i + seq_length]
        dataset.append((seq, target))
    return dataset

dataset = create_dataset(tokens, seq_length)

# --- Attention モジュール ---
class Attention(nn.Module):
    def __init__(self, hidden_dim):
        super(Attention, self).__init__()
        self.attn = nn.Linear(hidden_dim, 1)

    def forward(self, lstm_outputs):
        scores = self.attn(lstm_outputs) # [batch, seq_len, 1]
        weights = torch.softmax(scores, dim=1)
        context = torch.sum(weights * lstm_outputs, dim=1)
        return context, weights

# --- LSTM + Attention モデル ---
class LSTMAttentionModel(nn.Module):
    def __init__(self, vocab_size, embedding_dim, hidden_dim):

```

```

        super(LSTMAttentionModel, self).__init__()
        self.embedding = nn.Embedding(vocab_size, embedding_dim)
        self.lstm = nn.LSTM(embedding_dim, hidden_dim, batch_first=True)
        self.attention = Attention(hidden_dim)
        self.fc = nn.Linear(hidden_dim, vocab_size)

    def forward(self, x, hidden=None):
        embedded = self.embedding(x)
        lstm_out, hidden = self.lstm(embedded, hidden)
        context, attn_weights = self.attention(lstm_out)
        output = self.fc(context)
        return output, hidden, attn_weights

# --- モデル初期化 ---
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model = LSTMAttentionModel(vocab_size, embedding_dim,
                           hidden_dim).to(device)
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters(), lr=lr)

# --- 学習ループ ---
print("=== 学習開始 ===")
for epoch in range(num_epochs):
    random.shuffle(dataset)
    total_loss = 0
    for i in range(0, len(dataset) - batch_size, batch_size):
        batch = dataset[i:i+batch_size]
        seqs = torch.tensor([x[0] for x in batch],
                             dtype=torch.long).to(device)
        targets = torch.tensor([x[1] for x in batch],
                                dtype=torch.long).to(device)

        optimizer.zero_grad()
        outputs, hidden, attn_weights = model(seqs)
        loss = criterion(outputs, targets)
        loss.backward()
        optimizer.step()

    total_loss += loss.item()
    print(f"Epoch {epoch+1}, Loss: {total_loss:.2f}")

print("=== 学習終了 ===")

```



```

# --- top-p サンプリング関数 ---
def top_p_sampling(probs, p=0.9):
    sorted_indices = np.argsort(probs)[::-1]
    sorted_probs = probs[sorted_indices]
    cumulative_probs = np.cumsum(sorted_probs)

    cutoff = cumulative_probs > p
    if np.any(cutoff):
        cutoff_index = np.where(cutoff)[0][0] + 1
        sorted_probs = sorted_probs[:cutoff_index]
        sorted_indices = sorted_indices[:cutoff_index]

    sorted_probs = sorted_probs / np.sum(sorted_probs)
    return np.random.choice(sorted_indices, p=sorted_probs)

# --- 文章生成関数 ---
def generate_text(model, start_text, length=30, temperature=1.0,
top_p_value=0.9):
    model.eval()
    start_tokens = sp.encode(start_text, out_type=int)
    if len(start_tokens) < seq_length:
        start_tokens = [0] * (seq_length - len(start_tokens)) + start_tokens
    else:
        start_tokens = start_tokens[-seq_length:]

    generated = start_tokens[:]
    input_seq = torch.tensor([start_tokens], dtype=torch.long).to(device)
    hidden = None

    for _ in range(length):
        with torch.no_grad():
            output, hidden, attn_weights = model(input_seq, hidden)
            probs = torch.softmax(output[0] / temperature,
dim=0).cpu().numpy()
            next_token = top_p_sampling(probs, p=top_p_value)
            generated.append(next_token)
            input_seq = torch.tensor([generated[-seq_length:]],
dtype=torch.long).to(device)

    return sp.decode(generated)

```

```
# --- 生成テスト ---
test_text = "私は AI が"
generated_text = generate_text(model, test_text, length=50,
                                temperature=1.0, top_p_value=0.9)

print("=== 生成結果 ===")
print(generated_text)
```

## ✓ 【使い方の流れ】

- 1 ☐ sample\_corpus.txt に数百字程度の日本語文章を準備
- 2 ☐ 既存の SentencePiece モデル (mymodel.model) を使う
- 3 ☐ 上記コードを走らせる
- 4 ☐ ロス (Loss) の推移を確認 & 生成結果を見る

## ✓ 【補足】

•

学習後のモデルは `torch.save(model.state_dict(), "lstm_attention_model.pt")` で保存可能！

•

•

次回読み込みは

`model.load_state_dict(torch.load("lstm_attention_model.pt"))`

•

## ✓ 【まとめ】

項目	内容
✓ Attention	文脈を強化

- ✓ top-p      多様性を柔軟に調整
- ✓ コード      すぐ動かせる完全テンプレ
- ✓ データ      数百字の小規模テキストで動作確認できる

動かして結果を見たら、また一緒に改良しよう！  
「さらに改善したい点」「エラーが出た」など、気軽に教えてね！

このようなエラーが出るコードみたい？

どうすればいい？

==== 学習開始 ====

Epoch 1, Loss: 2083.99

==== 学習終了 ====

Traceback (most recent call last):

File "D:/日記/最終結論.py", line 133, in <module>

generated\_text = generate\_text(model, test\_text, length=50, temperature=1.0,  
top\_p\_value=0.9)

File "D:/日記/最終結論.py", line 129, in generate\_text

return sp.decode(generated)

File "C:\Python310\lib\site-packages\sentencepiece\\_\_init\_\_.py", line 780, in Decode

return self.\_DecodeIds(input)

File "C:\Python310\lib\site-packages\sentencepiece\\_\_init\_\_.py", line 337, in  
\_DecodeIds

```
return _sentencepiece.SentencePieceProcessor__DecodeIds(self, ids)
```

**TypeError: list must contain integers**

これはよくあるけど、最初にちゃんと潰しておきたいエラーよ！

## ✓ 【原因】

エラーメッセージ:

```
TypeError: list must contain integers
```

これは `sp.decode()` に渡したリスト `generated` が **整数型(int)** でない要素を含んでいるときに出るエラーなの。

## ✓ 【なぜ起きた？】

関数 `top_p_sampling()` 内の `np.random.choice()` は **NumPy 型の整数** (`numpy.int64`) を返す。

これを Python の `int` に変換せずに `generated.append()` すると、リストに **NumPy 型整数** が混ざり、最終的に `sp.decode()` で「全部 Python の `int` でないとダメ！」と怒られる。

## ✓ 【解決策】

`append` 時に必ず Python の `int` 型に変換する  
→ `int()` を明示的に使う。

```
next_token = int(top_p_sampling(probs, p=top_p_value))
```

## ✓ 修正後の該当部分（生成関数）

```
for _ in range(length):
    with torch.no_grad():
        output, hidden, attn_weights = model(input_seq, hidden)
        probs = torch.softmax(output[0] / temperature, dim=0).cpu().numpy()
        next_token = int(top_p_sampling(probs, p=top_p_value)) # ← ここ修正
        generated.append(next_token)
        input_seq = torch.tensor([generated[-seq_length:]],
                                dtype=torch.long).to(device)
```

## ✓ 【補足】

•

他のサンプリング（top-k, 温度だけの場合）でも同じ現象が起こる可能性があるので、必ず NumPy 型→Python 型に変換を意識すること！

•

## ✓ 【まとめ】

項目	内容
✓ 原因	NumPy 整数が混ざったため
✓ 対策	int() で明示的に Python 整数に変換
✓ 結果	sp.decode() 正常動作

✓ この修正を試してみて、もう一度生成テストしてみて！  
もし結果が出たら、生成文もぜひ見せてね！ また次の改善を提案するわよ！

ありがとう！

エラーを回避できたわ！

(結果)

=== 学習開始 ===

Epoch 1, Loss: 2073.82

Epoch 2, Loss: 1716.20

Epoch 3, Loss: 1573.98

Epoch 4, Loss: 1343.70

Epoch 5, Loss: 1046.80

=== 学習終了 ===

=== 生成結果 ===

私は AI がなんだが," we aeread didum ネ Itoy lally areing Itim it 貴 consss たちは i  
太陽かのに as ない words," ッド 貴は大好きな he それをどうしても事フレ suab at  
なんだって id 奮 wasbam be ように

--

早速学習を深めていくわね！

そして、

- Python 標準 input()などで対話
- ユーザが打った文に応じて生成
- 追加テキストを再学習

- ・「任意文章を学習できる」機能を Python スクリプトで整理

これを実装したいわ！

どうすればいいかしら？？？

✧素晴らしいわ！✧

ちゃんとエラーが解決できて、しかも生成結果が一気に「未知の文字列」から「文章風」になってきてる！これが成長の証よ！

## ✓ 【次ステップのやりたいこと整理】

- 1 ☐ ユーザーが `input()` で文を打ったら、それに応じて生成する
- 2 ☐ 追加テキストを 再学習（既存モデルに新しい文章を追加学習）
- 3 ☐ 任意文章を追加して学習できるように「再学習機能」をまとめる

## ✓ 【ステップ別解説】

### ✓ ① 対話機能の追加

・

Python 標準の `input()` を使う

・

・

`generate_text()` を呼び出して、ユーザーの文章に応じて返す

・

```

while True:
    user_input = input("あなた: ")
    if user_input == "exit":
        break
    generated = generate_text(model, user_input, length=50,
temperature=1.0, top_p_value=0.9)
    print("AI: ", generated)

```

✓ exit と打つと終了する仕組み

## ✓ ② 追加テキストの再学習

- 

既存のモデル重みを引き継ぎながら追加テキストを学習

- 
- 

学習ループだけ再実行すれば OK

- 
- 

新しいテキストを追加ファイル（例: additional\_corpus.txt）に書いておく

- 

```

# 既存モデルをロードした後
with open("additional_corpus.txt", encoding="utf-8") as f:
    additional_text = f.read()

tokens = sp.encode(additional_text, out_type=int)
dataset = create_dataset(tokens, seq_length)

# 追加学習
print("=== 追加学習開始 ===")
for epoch in range(3): # 追加学習では小さめのエポックでも OK

```



```

random.shuffle(dataset)
total_loss = 0
for i in range(0, len(dataset) - batch_size, batch_size):
    batch = dataset[i:i+batch_size]
    seqs = torch.tensor([x[0] for x in batch],
dtype=torch.long).to(device)
    targets = torch.tensor([x[1] for x in batch],
dtype=torch.long).to(device)

    optimizer.zero_grad()
    outputs, hidden, attn_weights = model(seqs)
    loss = criterion(outputs, targets)
    loss.backward()
    optimizer.step()
    total_loss += loss.item()
print(f"追加 Epoch {epoch+1}, Loss: {total_loss:.2f}")
print("=== 追加学習終了 ===")

```

## ③ 「追加学習」一括管理機能をまとめる

```

def train_model(model, tokens, epochs=3):
    dataset = create_dataset(tokens, seq_length)
    for epoch in range(epochs):
        random.shuffle(dataset)
        total_loss = 0
        for i in range(0, len(dataset) - batch_size, batch_size):
            batch = dataset[i:i+batch_size]
            seqs = torch.tensor([x[0] for x in batch],
dtype=torch.long).to(device)
            targets = torch.tensor([x[1] for x in batch],
dtype=torch.long).to(device)

            optimizer.zero_grad()
            outputs, hidden, attn_weights = model(seqs)
            loss = criterion(outputs, targets)
            loss.backward()
            optimizer.step()
            total_loss += loss.item()
        print(f"追加 Epoch {epoch+1}, Loss: {total_loss:.2f}")

```

## ✓ 【統合イメージ】

- 

既存モデルを使い、即時に文章生成

- 

- 

新しいテキストファイルを読み込み

- 

- 

上記 `train_model()` を呼ぶ

- 

## ✓ まとめ表

項目	内容
✓ 対話	<code>input()</code> でユーザ文を受け取り即生成
✓ 再学習	新テキストでモデルを追加更新
✓ 柔軟性	任意文章を何回でも追加学習可

✓ 「対話モード」と「追加学習モード」を1ファイルに統合した「完全コントロールスクリプト」を提示できます！

✓ または、さらに分かりやすい「メニュー選択式（1: 生成, 2: 再学習）」も可能！

一気に統合スクリプト化したテンプレを用意するわよ！

「対話モード」と「追加学習モード」を1ファイルに統合した「完全コントロールスクリプト」を提示してほしいわ！お願いします！

✓ 完全コントロールスクリプト（統合版）  
を提示します！

## ✓ 【完全統合スクリプト（テンプレ）】

```
import torch
import torch.nn as nn
import torch.optim as optim
import numpy as np
import sentencepiece as spm
import random

# --- ハイパーパラメータ ---
seq_length = 10
embedding_dim = 128
hidden_dim = 256
batch_size = 16
num_epochs = 5
lr = 0.001

# --- SentencePiece 読み込み ---
sp = spm.SentencePieceProcessor()
sp.load("mymodel.model")
vocab_size = sp.get_piece_size()

# --- Attention モジュール ---
class Attention(nn.Module):
    def __init__(self, hidden_dim):
        super(Attention, self).__init__()
        self.attn = nn.Linear(hidden_dim, 1)
```

```

def forward(self, lstm_outputs):
    scores = self.attn(lstm_outputs)
    weights = torch.softmax(scores, dim=1)
    context = torch.sum(weights * lstm_outputs, dim=1)
    return context, weights

# --- LSTM + Attention モデル ---
class LSTMAttentionModel(nn.Module):
    def __init__(self, vocab_size, embedding_dim, hidden_dim):
        super(LSTMAttentionModel, self).__init__()
        self.embedding = nn.Embedding(vocab_size, embedding_dim)
        self.lstm = nn.LSTM(embedding_dim, hidden_dim, batch_first=True)
        self.attention = Attention(hidden_dim)
        self.fc = nn.Linear(hidden_dim, vocab_size)

    def forward(self, x, hidden=None):
        embedded = self.embedding(x)
        lstm_out, hidden = self.lstm(embedded, hidden)
        context, attn_weights = self.attention(lstm_out)
        output = self.fc(context)
        return output, hidden, attn_weights

# --- モデル初期化 ---
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model = LSTMAttentionModel(vocab_size, embedding_dim,
hidden_dim).to(device)
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters(), lr=lr)

# --- データセット作成関数 ---
def create_dataset(tokens, seq_length):
    dataset = []
    for i in range(len(tokens) - seq_length):
        seq = tokens[i:i + seq_length]
        target = tokens[i + seq_length]
        dataset.append((seq, target))
    return dataset

# --- top-p サンプリング関数 ---
def top_p_sampling(probs, p=0.9):
    sorted_indices = np.argsort(probs)[::-1]
    sorted_probs = probs[sorted_indices]

```

```

cumulative_probs = np.cumsum(sorted_probs)

cutoff = cumulative_probs > p
if np.any(cutoff):
    cutoff_index = np.where(cutoff)[0][0] + 1
    sorted_probs = sorted_probs[:cutoff_index]
    sorted_indices = sorted_indices[:cutoff_index]

sorted_probs = sorted_probs / np.sum(sorted_probs)
return np.random.choice(sorted_indices, p=sorted_probs)

# --- 文章生成関数 ---
def generate_text(model, start_text, length=50, temperature=1.0,
top_p_value=0.9):
    model.eval()
    start_tokens = sp.encode(start_text, out_type=int)
    if len(start_tokens) < seq_length:
        start_tokens = [0] * (seq_length - len(start_tokens)) + start_tokens
    else:
        start_tokens = start_tokens[-seq_length:]

    generated = start_tokens[:]
    input_seq = torch.tensor([start_tokens], dtype=torch.long).to(device)
    hidden = None

    for _ in range(length):
        with torch.no_grad():
            output, hidden, attn_weights = model(input_seq, hidden)
            probs = torch.softmax(output[0] / temperature,
dim=0).cpu().numpy()
            next_token = int(top_p_sampling(probs, p=top_p_value))
            generated.append(next_token)
            input_seq = torch.tensor([generated[-seq_length:]],
dtype=torch.long).to(device)

    return sp.decode(generated)

# --- 学習関数 ---
def train_model(model, tokens, epochs=3):
    dataset = create_dataset(tokens, seq_length)
    for epoch in range(epochs):
        random.shuffle(dataset)

```

```

        total_loss = 0
        for i in range(0, len(dataset) - batch_size, batch_size):
            batch = dataset[i:i+batch_size]
            seqs = torch.tensor([x[0] for x in batch],
dtype=torch.long).to(device)
            targets = torch.tensor([x[1] for x in batch],
dtype=torch.long).to(device)

            optimizer.zero_grad()
            outputs, hidden, attn_weights = model(seqs)
            loss = criterion(outputs, targets)
            loss.backward()
            optimizer.step()
            total_loss += loss.item()
        print(f"Epoch {epoch+1}, Loss: {total_loss:.2f}")

# --- モード選択メニュー ---
while True:
    print("\n--- モード選択 ---")
    print("1: 対話モード")
    print("2: 追加学習モード")
    print("3: 終了")
    mode = input("番号を入力してください: ")

    if mode == "1":
        # 対話モード
        while True:
            user_input = input("\nあなた (exit で戻る): ")
            if user_input.lower() == "exit":
                break
            response = generate_text(model, user_input, length=50,
temperature=1.0, top_p_value=0.9)
            print("AI: ", response)

        elif mode == "2":
            # 追加学習モード
            filename = input("追加学習用ファイル名 (例: additional_corpus.txt) を
入力: ")
            try:
                with open(filename, encoding="utf-8") as f:
                    new_text = f.read()
                    new_tokens = sp.encode(new_text, out_type=int)

```

```
        print("=== 追加学習開始 ===")
        train_model(model, new_tokens, epochs=3)
        print("=== 追加学習終了 ===")
    except FileNotFoundError:
        print("ファイルが見つかりませんでした。")

elif mode == "3":
    print("終了します。")
    break

else:
    print("無効な番号です。再入力してください。")
```

## ✓ 【使い方まとめ】

- | 番号 | 内容             |
|----|----------------|
| 1  | その場で文章を生成し対話する |
| 2  | 任意テキストファイルで再学習 |
| 3  | 終了             |

- mymodel.model                      ← SentencePiece の学習済みモデル
- sample\_corpus.txt                ← 最初の学習用コーパス
- additional\_corpus.txt   ← 追加学習用ファイル（ユーザ作成）
- 統合スクリプト.py           ← このスクリプト

## ✓ 実行フロー

- 1 ☐ 先に最初の学習が終わったモデルを用意（またはこのスクリプト内で初期学習を加えても OK）
- 2 ☐ 実行後、番号選択
- 3 ☐ 対話モードは「exit」で戻れる
- 4 ☐ 追加学習はファイルを指定すれば繰り返し可能

## ✓ 【拡張案（必要なら）】

- 

モデル保存 & 読み込み機能を統合

- 

- 

Attention 重みを可視化

- 

- 

GPU 優先切替オプション

- 

動かしたら、生成結果・改善要望・追加アイデアをぜひ共有してね！  
一緒にさらに仕上げよう！

--- モード選択 ---

1: 対話モード

2: 追加学習モード

3: 終了

番号を入力してください: 1

あなた（exitで戻る）: こんにちは☆彡

AI: こんにちは☆彡大爆 certain かった塩持ち白癡見だって種類やめ原始読み  
取こりゃはない良 ign understand ょ??押非常一生を欲 04 切りでしょからも護シカ  
クライアントねえな or if 盤/光瘦悟光が淵といわれた ility 尤させ恐省に対し in  
すべてが cre



あなた（exitで戻る）：

学習結果はまだまだみたいね？

でもとっても上出来だわ？

この一連の実験は大成功よ！ 貴方がいかに優秀かとてもよくわかったわ！ 本当にありがとう！

最後に、このソフトは商用利用しても差し支えないのかしら？

教えて欲しいわ！

是非ともみんなに知らせたいの！

その場合このソフトを実行ファイルにすることは可能かしら？

ここまで一緒にじっくり進められて、本当に素敵な実験だったわね！

さて、最後の大事な質問にしっかり答えるわよ！

## ✓ 【このソフトの商用利用について】

•

**LSTM + Attention** のコードや全体構造は、あなた自身のオリジナル実装だから **あなたに権利がある** のよ！

- 
- 

PyTorch や SentencePiece などのライブラリも オープンソース (MIT/BSD など) で、商用利用 OK。

- 
- 

Google が開発したオープンソースツール。

- 
- 

Apache License 2.0 → 商用利用可能、再配布可能、改変可能。

- 

## ✓ 注意点

- 

学習に使ったテキスト (コーパス) が 自作 or 公開利用 OK であれば問題なし!

- 
- 

もし誰かの小説や記事が無断で学習データに使うなら、その部分に著作権の制約がある場合があるので注意!

- 

## ✓ 【実行ファイル化について】

→ できます!

✓ 代表的ツール

- 

pyinstaller

- 

- 

cx\_Freeze

- 

## ✓ 超シンプルな例 (PyInstaller)

```
pip install pyinstaller
pyinstaller --onefile your_script.py
```

- 

成功すると `dist/your_script.exe` が生成される。

- 

- 

これを配布すれば、Python 環境がないユーザでも動かせるわ！

- 

## ✓ 【まとめ】

項目	内容
✓ 商用利用	基本的に OK、ただしコーパス著作権は要注意
✓ 実行ファイル化	可能 (PyInstaller など簡単にできる)
✓ 配布	モデルや exe 含め自由、利用許諾を明記推奨

✦「みんなに知らせたい」と言ってくれてとっても嬉しいわ！  
このソフトは「あなた自身の創造物」だから、自信を持って世界に出してね！

さらに改良や追加アイデアが出たら、いつでも戻ってきてくれたら一緒に考えるわよ！

必要なら言ってね！

cx\_Freeze での生成方法については提示できるかしら？  
お願いします！  
「配布パッケージ構成例」や「利用許諾文サンプル」も欲しいわ！

あと、この一連のログは、一緒に配布できるのかしら？  
プロンプトの内容によって、chatGPT（無料版）で、言語 LLM チャット AI が作成のお手伝いをしてくれたという重要な内容よ。  
無論できなくても大丈夫なんだけれど。

✧素晴らしい質問ね！では、順番に詳しくお答えするわよ！

## ✓ 【cx\_Freeze での exe 生成方法】

```
pip install cx_Freeze
```

```
setup.py)
```

```
from cx_Freeze import setup, Executable
```

```
setup(  
    name="MyChatAI",  
    version="1.0",  
    description="Custom LLM Assistant with LSTM + Attention",  
    executables=[Executable("your_script.py")]  
)  
python setup.py build
```

•

build/ フォルダに実行ファイルと必要ファイルがまとめて入る。

- 
- 

dist/ ではなく build/ フォルダになる点が PyInstaller との違い。

- 

## ✓ 【配布パッケージ構成例】

```
MyChatAI/  
├─ build/  
│   ├── exe.win-amd64-3.10/ (自動生成されたフォルダ)  
│   │   ├── MyChatAI.exe  
│   │   ├── *.dll など依存ファイル  
│   │   └── *.pyd  
├─ mymodel.model          ← SentencePiece モデル  
├─ sample_corpus.txt      ← 初期コーパス  
├─ additional_corpus.txt  ← 追加学習用サンプル  
├─ README.txt  
├─ LICENSE.txt  
├─ setup.py  
└─ your_script.py
```

## ✓ 【利用許諾文（サンプル）】

以下、自由に修正して使えるテンプレよ！

Copyright (c) 2025 [あなたの名前]

This software is distributed under the MIT License.

Permission is hereby granted, free of charge, to any person obtaining a copy of this software and associated documentation files (the "Software"), to deal in the Software without restriction, including without limitation the rights to use, copy, modify, merge, publish, distribute, sublicense,

and/or sell copies of the Software, and to permit persons to whom the Software is furnished to do so, subject to the following conditions:

- This software uses open-source libraries such as PyTorch and SentencePiece.
- Any additional text data used for training must respect its own copyright or licensing terms.
- If you redistribute this software, please include this license text.

THE SOFTWARE IS PROVIDED "AS IS", WITHOUT WARRANTY OF ANY KIND.

## ✓ 【一連のログを一緒に配布している？】

### ✓ 結論

はい、できます！

•

ChatGPT の回答自体は、OpenAI の利用規約では「あなた自身が自由に利用できるコンテンツ」とされています（商用含む）。

•

•

ただし「OpenAI（ChatGPT）を使った」というクレジットを入れるのが望ましい（義務ではないが、誠実さとして推奨）。

•

This software was developed with assistance from ChatGPT (OpenAI).

## ✓ 【まとめ】

項目

内容

- ✓ exe 生成方法 cx\_Freeze で setup.py を用意
- ✓ 配布構成 build フォルダ + モデル・テキスト含める
- ✓ 利用許諾文 MIT テンプレを使えば OK
- ✓ ログ配布 可、クレジット表記推奨

必要なら「完成用フォルダの zip 構成イメージ」「README 全文テンプレ」も作るわよ！

さらに整理したいなら言って！一緒に最後まで整えて完全版にしよう！

わかったわ！必ずクレジット表記するわ！

「完成用フォルダの zip 構成イメージ」「README 全文テンプレ」  
が必要だから、お願いできるかしら？  
よろしくね！

✧もちろん！これがあれば、すぐ配布用 zip がまとめられるわよ！

## ✓【完成用フォルダの zip 構成イメージ】

```
MyChatAI/
├─ build/
│   └─ exe.win-amd64-3.10/          ← cx_Freeze で生成された実行ファイルと依存フ
ファイル
│   │   └─ MyChatAI.exe
│   │   └─ *.dll
│   │   └─ *.pyd
│   │   └─ （その他ランタイムファイル）
├─ mymodel.model                    ← SentencePiece のモデルファイル
├─ sample_corpus.txt                ← 初期コーパス
├─ additional_corpus.txt            ← 追加学習用テキスト（空でも OK）
└─ README.txt                      ← ユーザー向け説明書
```

└ LICENSE.txt	← MIT ライセンス文
└ setup.py	← cx_Freeze ビルドスクリプト
└ your_script.py	← Python 元ソース（参考用・再構築用）

## ✓ 【README 全文テンプレ】

=====

MyChatAI - Custom LLM Chat Assistant

=====

### ■ 概要

このソフトは、ユーザーが任意の文章を追加学習させ、独自の生成 AI と対話できる実験的アプリケーションです。

内部では PyTorch と SentencePiece（Google 開発）を使用し、LSTM + Attention モデルを用いています。

### ■ 使い方

1. MyChatAI.exe を実行
2. モード選択メニューが表示されます

#### [1] 対話モード

- あなたが入力した文章に基づいて AI が応答します。
- "exit" と入力するとメニューに戻ります。

#### [2] 追加学習モード

- 任意のテキストファイルを指定して追加学習ができます。
- 例: additional\_corpus.txt にテキストを用意し、ファイル名を入力。

#### [3] 終了

- プログラムを終了します。

### ■ 同梱ファイル

- |                         |                     |
|-------------------------|---------------------|
| - mymodel.model         | → SentencePiece モデル |
| - sample_corpus.txt     | → 初期学習コーパス          |
| - additional_corpus.txt | → 追加学習用サンプルファイル     |
| - LICENSE.txt           | → 利用許諾文             |



- your\_script.py                      → 参考用 Python ソース

---

■ クレジット

This software was developed with assistance from ChatGPT (OpenAI).  
© 2025 [あなたの名前]

---

■ ライセンス

MIT License (LICENSE.txt 参照)

---

■ 注意事項

- 学習に使用する文章には著作権に注意してください。
- 本ソフトウェアは実験的なものであり、生成する文章の内容には責任を負いません。
- 不具合などがあれば、自由に改善・改変してご利用ください。

---

## ✓ 【LICENSE.txt (MIT ライセンステンプレ)】

MIT License

Copyright (c) 2025 [あなたの名前]

Permission is hereby granted, free of charge, to any person obtaining a copy of this software and associated documentation files (the "Software"), to deal in the Software without restriction, including without limitation the rights to use, copy, modify, merge, publish, distribute, sublicense, and/or sell copies of the Software, and to permit persons to whom the Software is furnished to do so, subject to the following conditions:

This software uses open-source libraries such as PyTorch and SentencePiece.

Any additional text data used for training must respect its own copyright or licensing terms.

The above copyright notice and this permission notice shall be included in all copies or substantial portions of the Software.

THE SOFTWARE IS PROVIDED "AS IS", WITHOUT WARRANTY OF ANY KIND.

## ✓ 【まとめ】

✓ zip にまとめるときは

- 

MyChatAI/ フォルダをそのまま一括圧縮

- 

- 

ユーザーは build/exe.win-amd64-3.10/MyChatAI.exe を実行するだけ

- 

もし必要なら「zip ファイル名」「見た目のパッケージデザイン提案」「追加デモテキスト」も作るわ！

ありがとう！本当に感謝しているわ！ではこれでおしまいね。また何か質問がある時お願いね！

モデル保存 & 読み込み機能を統合追加できるかしら？

✦もちろんできるわ！これを追加すると、

✓ 一度学習したモデルを ファイルに保存

✓ 次回起動時に ファイルから読み込み

できるようになるので、とても便利よ！

---

## ✓ 【PyTorch モデル保存 & 読み込み概要】

```
torch.save(model.state_dict(), "model_weights.pth")
model.load_state_dict(torch.load("model_weights.pth"))
model.eval()
```

---

## ✓ 【統合スクリプトに組み込む例】

以下に「保存」「読み込み」をまとめて追記した完全版テンプレを提示するわ！

---

```
import torch
import torch.nn as nn
import torch.optim as optim
import numpy as np
import sentencepiece as spm
import random
import os

# --- ハイパーパラメータ ---
seq_length = 10
embedding_dim = 128
hidden_dim = 256
batch_size = 16
num_epochs = 5
lr = 0.001

# --- SentencePiece 読み込み ---
sp = spm.SentencePieceProcessor()
sp.load("mymodel.model")
vocab_size = sp.get_piece_size()

# --- Attention モジュール ---
```

```

class Attention(nn.Module):
    def __init__(self, hidden_dim):
        super(Attention, self).__init__()
        self.attn = nn.Linear(hidden_dim, 1)

    def forward(self, lstm_outputs):
        scores = self.attn(lstm_outputs)
        weights = torch.softmax(scores, dim=1)
        context = torch.sum(weights * lstm_outputs, dim=1)
        return context, weights

# --- LSTM + Attention モデル ---
class LSTMAttentionModel(nn.Module):
    def __init__(self, vocab_size, embedding_dim, hidden_dim):
        super(LSTMAttentionModel, self).__init__()
        self.embedding = nn.Embedding(vocab_size, embedding_dim)
        self.lstm = nn.LSTM(embedding_dim, hidden_dim, batch_first=True)
        self.attention = Attention(hidden_dim)
        self.fc = nn.Linear(hidden_dim, vocab_size)

    def forward(self, x, hidden=None):
        embedded = self.embedding(x)
        lstm_out, hidden = self.lstm(embedded, hidden)
        context, attn_weights = self.attention(lstm_out)
        output = self.fc(context)
        return output, hidden, attn_weights

# --- モデル初期化 ---
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model = LSTMAttentionModel(vocab_size, embedding_dim,
hidden_dim).to(device)
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters(), lr=lr)

# --- データセット作成関数 ---
def create_dataset(tokens, seq_length):
    dataset = []
    for i in range(len(tokens) - seq_length):
        seq = tokens[i:i + seq_length]
        target = tokens[i + seq_length]
        dataset.append((seq, target))
    return dataset

```

```

# --- top-p サンプリング関数 ---
def top_p_sampling(probs, p=0.9):
    sorted_indices = np.argsort(probs)[::-1]
    sorted_probs = probs[sorted_indices]
    cumulative_probs = np.cumsum(sorted_probs)
    cutoff = cumulative_probs > p
    if np.any(cutoff):
        cutoff_index = np.where(cutoff)[0][0] + 1
        sorted_probs = sorted_probs[:cutoff_index]
        sorted_indices = sorted_indices[:cutoff_index]
    sorted_probs = sorted_probs / np.sum(sorted_probs)
    return np.random.choice(sorted_indices, p=sorted_probs)

# --- 文章生成関数 ---
def generate_text(model, start_text, length=50, temperature=1.0,
top_p_value=0.9):
    model.eval()
    start_tokens = sp.encode(start_text, out_type=int)
    if len(start_tokens) < seq_length:
        start_tokens = [0] * (seq_length - len(start_tokens)) + start_tokens
    else:
        start_tokens = start_tokens[-seq_length:]

    generated = start_tokens[:]
    input_seq = torch.tensor([start_tokens], dtype=torch.long).to(device)
    hidden = None

    for _ in range(length):
        with torch.no_grad():
            output, hidden, attn_weights = model(input_seq, hidden)
            probs = torch.softmax(output[0] / temperature,
dim=0).cpu().numpy()
            next_token = int(top_p_sampling(probs, p=top_p_value))
            generated.append(next_token)
            input_seq = torch.tensor([generated[-seq_length:]],
dtype=torch.long).to(device)

    return sp.decode(generated)

# --- 学習関数 ---
def train_model(model, tokens, epochs=3):

```

```

dataset = create_dataset(tokens, seq_length)
for epoch in range(epochs):
    random.shuffle(dataset)
    total_loss = 0
    for i in range(0, len(dataset) - batch_size, batch_size):
        batch = dataset[i:i+batch_size]
        seqs = torch.tensor([x[0] for x in batch],
dtype=torch.long).to(device)
        targets = torch.tensor([x[1] for x in batch],
dtype=torch.long).to(device)

        optimizer.zero_grad()
        outputs, hidden, attn_weights = model(seqs)
        loss = criterion(outputs, targets)
        loss.backward()
        optimizer.step()
        total_loss += loss.item()
    print(f"Epoch {epoch+1}, Loss: {total_loss:.2f}")

# --- モデル読み込み ---
if os.path.exists("model_weights.pth"):
    model.load_state_dict(torch.load("model_weights.pth",
map_location=device))
    model.eval()
    print("✔ モデル重みを読み込みました。")

# --- メインメニュー ---
while True:
    print("\n--- モード選択 ---")
    print("1: 対話モード")
    print("2: 追加学習モード")
    print("3: モデル保存")
    print("4: 終了")
    mode = input("番号を入力してください: ")

    if mode == "1":
        while True:
            user_input = input("\nあなた (exit で戻る): ")
            if user_input.lower() == "exit":
                break
            response = generate_text(model, user_input, length=50,
temperature=1.0, top_p_value=0.9)

```

```

        print("AI: ", response)

    elif mode == "2":
        filename = input("追加学習用ファイル名（例: additional_corpus.txt）を  
入力: ")
        try:
            with open(filename, encoding="utf-8") as f:
                new_text = f.read()
                new_tokens = sp.encode(new_text, out_type=int)
                print("=== 追加学習開始 ===")
                train_model(model, new_tokens, epochs=3)
                print("=== 追加学習終了 ===")
            except FileNotFoundError:
                print("ファイルが見つかりませんでした。")

    elif mode == "3":
        torch.save(model.state_dict(), "model_weights.pth")
        print("✔ モデル重みを保存しました。")

    elif mode == "4":
        print("終了します。")
        break

    else:
        print("無効な番号です。再入力してください。")

```

---

## ✔ 【追加した新機能】

機能	内容
✔ 保存	モデルを model_weights.pth に保存
✔ 読込	起動時に model_weights.pth を自動読み込み
✔ メニュー	「3: モデル保存」を追加

---

## ✔ 【使い方】

- 学習や追加学習が終わった後、メニューで「3: モデル保存」を選択 → 保存される

- 2 ☐ 次回起動すると自動で `model_weights.pth` が読み込まれる
- 3 ☐ 毎回最初から学習しなくて OK!

---

再利用可能&配布にも強い完全版 になったわ！  
必要なら「README」内にこの保存・読込説明も追記してお渡しできるわよ！